



中国管理科学
Chinese Journal of Management Science
ISSN 1003-207X, CN 11-2835/G3

《中国管理科学》网络首发论文

题目：缓解牛鞭效应的新途径：人机协同的智慧决策机器人
作者：李勇，陈元，于辉
网络首发日期：2022-09-13
引用格式：李勇，陈元，于辉. 缓解牛鞭效应的新途径：人机协同的智慧决策机器人[J/OL]. 中国管理科学.
<https://kns.cnki.net/kcms/detail/11.2835.G3.20220909.1743.006.html>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

缓解牛鞭效应的新途径：人机协同的智慧决策机器人

李 勇, 陈 元, 于 辉

(重庆大学 经济与工商管理学院, 重庆 400030)

摘要：牛鞭效应是指供应链上需求变异并逐级放大的现象,缓解牛鞭效应是供应链管理的核心任务之一。本文构建了由一个零售商、一个批发商、一个分销商和一个制造商组成的四级供应链,把人工智能中的深度强化学习技术引入到供应链管理之中,设计了人机协同的智慧决策机器人(核心算法),用于改善供应链中分销商决策。智慧实验结果表明:供应链上各个节点的“方差比、平均成本以及服务水平”等指标全面改进,牛鞭效应得到极大缓解。本文为研究供应链管理中的牛鞭效应提供了一种全新的视角与途径,赋予了供应链管理智慧决策的价值。

关键词：牛鞭效应; 人机协同; 智慧决策机器人; 供应链管理

1 引言

牛鞭效应是指在供应链管理中,顾客需求信息向上游传递时,出现的需求信息波动逐级放大的现象,即,节点订货量方差大于顾客需求量方差^[1,2]。该现象最早由Forrester^[3]发现,他通过仿真发现这是行业组织系统随时间动态变化的结果。后来Sternan^[4]设计了“Beer Distribution Game”,通过模拟仿真分析并证实了牛鞭效应,进一步认为牛鞭效应是人的系统性的非理性的行为造成的。随后Lee等^[1,2]借助数理模型对两级供应链上的牛鞭效应进行了刻画,提出牛鞭效应主要来源于需求预测、批量订购、短缺博弈以及价格波动,从而认为牛鞭效应是人在理性心理的驱使下选择最优决策后相互影响的结果。牛鞭效应增加了上游节点的库存成本以及缺货成本,运输提前期的存在大幅度降低供应链节点企业的服务水平,极大削弱企业竞争力。如,2008年以后,李宁公司代理商对经营业绩盲目乐观,加上传统的服装产销模式,导致从零售商到制造商,损额达20亿。需求出现极大偏差,企业库存冗余增加,即,牛鞭效应产生,致使李宁公司因库存积压亏。

基于牛鞭效应给供应链节点企业带来的问题,缓解牛鞭效应成为了供应链管理研究者的核心任务之一。目前的缓解途径主要有以下几类。第一类是信息共享。Cachon和Fisher^[5]、Chen等^[6]、Dejonckheere等^[7]通过构建二级供应链甚至多级供应链,对比

有无信息共享策略下的牛鞭效应,发现共享信息的确可以缓解牛鞭效应,同时降低供应链成本。第二类是协调订货,Odonnell等^[8]、Badakhshan等^[9]引进遗传算法寻找供应链成员之间最优的补货决策,通过实验证明在供应链中引用遗传算法可以缓解牛鞭效应,Tsay和Lovejoy^[10]、Eppen和Iyer^[11]通过模拟,证明数量柔性契约可以潜在抑制牛鞭效应。第三类是库存管理,最常用的是供应链管理库存(Vendor Managed Inventory, VMI),Disney和Towill^[12]比较了VMI供应链与传统的“串联”供应链的预期绩效,发现在两级供应链上,VMI供应链的牛鞭效应得到显著降低。第四类是缩短提前期。陈佳莉和郭春香^[13]通过数学建模及仿真发现减少提前期可以缓解牛鞭效应,但是尤建新等^[14]认为生产提前期不是越短越好,而是存在一个最优值。此外,也有学者使用其他方法来缓解牛鞭效应,如唐亮和靖可^[15]采用的H[∞]鲁棒控制策略以及陈长彬等^[16]提出的资产组合管理方法等。

机器学习技术可以从以往大量数据中提取经验,进而处理非线性问题。Carbonneau等^[17]利用先进的机器学习技术,包括神经网络、递归神经网络和支持向量机,来预测供应链末端的扭曲需求,结果表明该类技术预测效果很好,但是预测精度不够。2006年,深度学习的浪潮开始兴起,Hinton和Salakhutdinov^[18]提出用自编码器降低数据的维度,并且可以采用预训练的方式来抑制梯度消失问题。在此基础上,Kong和Li^[19]利用由多层受限玻尔兹曼机组成的深度信念网络建立了供应链柔性网络,提升了预测精度,更提高了供应链的灵活性。但是张荣等^[20]认为深度学习在面临动态交互环境时表现出一定的决策劣势。Mnih等^[21,22]提出的深度强化学习网络(Deep Q-Network, DQN)可以解决动态交互决策问题,并在视频游戏和机器博弈领域表现出良好的性能。

基金项目：国家自然科学基金面上资助项目(72172019, 71872021), 中央高校基本科研专项资金(2021CDJSKJC11)

通讯作者简介：于辉(1973—),男(汉族),重庆人,博士,重庆大学经济与工商管理学院教授,博士生导师,研究方向:供应链管理, Email: yuhui@cqu.edu.cn.

基于这种优点, Oroojlooyjadid 等^[23]将 DQN 引入啤酒分销博弈, 并证实 DQN 参与的供应链产生的成本与基本库存策略下的成本非常相似, 并在一定程度上有所减小, 但是他们没有研究牛鞭效应。在实践环节, Chien 等^[24]针对半导体供应链组件和模块领先的分销商, 为应对工业 3.5, 设计了基于 DQN 的需求预测统一框架, 以解决由于需求不对称导致的库存积压问题, 实证结果表明该方法具有实际可行性, 并且已嵌入公司的决策支持系统。

因此, 针对上述已有缓解牛鞭效应的方法, 本文基于经典文献[1,2,6]对牛鞭效应的研究, 提出了一种新的缓解牛鞭效应的途径, 即基于深度强化学习的人机协同的智慧决策机器人(Intelligent decision-making robot, IDMR)。智慧实验将 IDMR 整合进供应链, 用以改善分销商决策, 决策“老师”将自己的理性决策经验教授给 IDMR, 并在 IDMR 决策制定过程中限制决策范围, 当 IDMR 决策影响理论最优库存时, 决策“老师”施加严厉的惩罚, 禁止 IDMR 向上游订货, 以协调整条供应链的服务水平以及成本, 最终实现极大地缓解牛鞭效应的目标。

本文着重研究 IDMR 参与下的供应链上的牛鞭效应新现象。智慧实验结果表明, 这种人机协同的智慧决策方法可以有效减少订货量方差与顾客需求量方差之比, 在减小整条供应链总成本的同时, 极大降低供应链上游成本, 提升供应链节点的服务水平, 发挥了缓解牛鞭效应的巨大作用。因此, 本文为研究供应链管理中的牛鞭效应提供了一种全新的视角与途径, 这给供应链管理者在供应链上游布局新模式以新的启示。

2 经典供应链订货决策

为了让智慧决策机器人能够学到人类理论最优的决策, 更好的适应决策环境, 并最终做出最优决策, 本文采用 Chen^[6]刻画牛鞭效应模型, 供应链条按照 Sterman^[4]设计的经典啤酒游戏模式运行。

2.1 经典供应链模型

图 1 为零售商、批发商、分销商、制造商组成的经典多级供应链模型。




图 1 经典多级供应链模型

定义每个供应链节点为节点

$k(k=1, 2, 3, 4)$, 假设在每个周期 t 都发生如下事件: 第一步, 节点 k 收到下游节点 $k-1$ 的订单 $q_t^{k-1}(k \geq 2)$, 观察自身库存水平, 并向上游节点 $k+1$ 按照理性决策原则补货; 第二步, 节点 k 收到上游节点 $k+1$ 发出的 L 运输周期前的货物; 第三步, 节点 k 满足下游节点 $k-1$ 的订单 q_t^{k-1} , 并更新自身库存和缺货。

2.2 理性决策

供应链上每个节点所作决策都是理性决策, 均按照如下零售商的订货步骤依次向上游订货。零售商首先根据最近 p 个周期的需求对当期顾客需求 D_t 进行简单移动平均(Simple Moving Average, SMA)预测, 得到 L 提前期内的预测需求 $\hat{D}_t^L$ 以及预测误差 $\hat{\sigma}_{et}^L$, 然后根据订至点库存策略(Order-Up-To, OUT)计算期望库存 S_t , 最后做出补货决策 q_t 。该理性决策以最大化服务水平(Service Level, SL)为目标。零售商所观察到的周期 t 的需求遵循如下随机过程

$$D_t = d + \rho D_{t-1} + \varepsilon_t \quad (1)$$

其中, d 是非负常量, $\rho(|\rho| < 1)$ 是相关系数, ε_t 是误差项, 服从独立同正态分布。期望库存 S_t 的具体表达式如下:

$$S_t = \hat{D}_t^L + z \hat{\sigma}_{et}^L \quad (2)$$

其中, z 表示安全库存系数。SMA 预测过程如下(3)式所示:

$$\hat{D}_t^L = L \left[\frac{\sum_{i=1}^p D_{t-i}}{p} \right], \quad \hat{\sigma}_{et}^L = C_{L,\rho} \sqrt{\frac{\sum_{i=1}^p (e_{t-i})^2}{p}} \quad (3)$$

其中, e_t 表示一个周期的预测误差, 即

$$e_t = D_t - \hat{D}_t^L, \quad C_{L,\rho} \text{ 表示 } L、\rho \text{ 和 } p \text{ 的常数。}$$

订货策略如下:

$$q_t = S_t - IP_t = S_t - (NS_t + WIP_t) \quad (4)$$

其中 IP_t 表示现有库存, NS_t 表示净库存, WIP_t 表示在途库存。

牛鞭效应量化方式如下(5)式所示。

$$BWE = \frac{\text{var}(q_t)}{\text{var}(D_t)} \quad (5)$$

其中, $\text{var}(q_t)$ 表示零售商周期 t 时的订货量方差, $\text{var}(D_t)$ 表示周期 t 时的顾客需求量方差。

2.3 牛鞭效应

基于 Chen^[6]的理性决策和 Sterman^[4]设计的啤酒游戏模式, 本文复盘了动态的牛鞭效应现象。供应链上的方差比、平均成本以

及服务水平分别呈现如下图 2、图 3 以及图 4 的特征。

1) 方差比

表 1 理性决策下的牛鞭效应(保留小数点后 2 位)

节点	需求(均值)	订单(均值)	方差比
零售商	19.48	19.48	5.42
批发商	19.48	19.49	27.19
分销商	19.49	19.53	110.33
制造商	19.53	19.66	359.44

注: $\rho=0.5$, $C_{L,\rho}=2$, $d=10$, $\varepsilon \sim N(0,5)$, $z=2$, $L=2$, $p=5$, 订货运行周期为 20000, 各个节点初始库存均为 10。




图 2 理性决策下的方差比

如表 1 所示, 在理性决策下, 经过 20000 个周期的连续动态订货与发货, 供应链上各个节点都表现出订单均值与需求均值近似相等的特征, 该现象与文献 [17] 的结论相一致。但是如图 2 所示, 在动态订货、发货的场景下, 从零售商到制造商, 各个节点订货量的方差与顾客需求量的方差之比在订货初期呈现出逐级放大并且激增的现象, 后期逐渐平稳, 但是逐级放大的现象依旧存在, 这说明在经典多级供应链模型下, 随着订货周期的增加, 供应链上的牛鞭效应有所缓和但仍然较为严重。

2) 平均成本




图 3 理性决策下的平均成本

图 3 表示在理性决策下, 随着订货周期的增加, 供应链各个节点从订货开始到当前订货周期的累计成本的平均成本。如上图 3 所示, 从零售商到制造商, 各个节点的平均成本在订货初期呈现出激增的现象并且逐级增加, 到订货后期, 平均成本逐渐缓和, 最后趋于平稳, 其中, 制造商 20000 个周期的平均成本大约是零售商的 39 倍。

3) 服务水平

基于理性决策^[6], 本文采用有货率来衡量服务水平, 即所有订货次数中有货的比例, 即

$$SL = 1 - \frac{\text{缺货次数}}{\text{订货次数}} \quad (6)$$

并且服务水平与安全库存系数存在如下关系:

$$SL = \phi(z) \quad (7)$$




图 4 理性决策下的服务水平

在理性决策下, 供应链上各个节点以满足 97.7% ($z=2$) 的服务水平为目标。从理论上讲, 各个节点都可以达到 97.7% 的服务水平。但是从实验结果来看, 如上图 4 所示, 虽然在订货后期, 服务水平逐渐稳定在一个较高的值, 但是除了制造商,

其他节点均无法达到 97.7%的服务水平，其中零售商的服务水平最低，只达到了 87.5%左右。

3 智慧决策机器人设计

虽然外部市场需求相对稳定，但是在经典多级供应链模型下，各级节点根据直接下游的需求向上游订货，在理性决策下会产生巨大的牛鞭效应。由于 DQN^[21,22]本身能够适应动态变化的环境，并在供应链决策上体现出较高的优越性^[23]，所以本文基于 DQN 设计了人机协同的智慧决策机器人，并将智慧决策机器人整合进供应链，用以改善分销商决策。它的作用机理是基于 Agent 与环境进行交互，然后从环境中获得奖赏并反馈给动作，包含 4 个基本要素，即策略、奖惩反馈、值函数和环境，以及一个主要要素，即人类订货的最优决策经验——理性决策“老师”。决策“老师”将自己的决策经验教授给智慧决策机器人，并且在发现智慧决策机器人决策失误时及时给以干扰，即人类决策充当“教师”角色，智慧决策机器人扮演“学生”的角色，“教师”在“学生”犯错误时及时对“学生”的行为进行批评指正，即人机协同机制：传授经验、限制决策、惩罚机制，大致流程如图 5 所示。




图 5 智慧多级供应链模型

3.1 环境适应

在智慧多级供应链中，智慧决策机器人所在节点是 $k=3$ ，于周期 t 接收批发商订单 q_t^2 ，并观察当期库存 S_t^3 、在途库存 WIP_t^3 和上期运输货物 $Trans_{t-1}^3$ ，通过观察并适应环境，以及在决策“老师”指导下做出回报最大的决策，然后向制造商订货，同时满足批发商当期需求。

当订货次数超过 200 时，智慧决策机器人使用值网络逼近值函数，值函数的参数化表现形式为 $Q(s, a; \theta_i)$ ，其中 θ_i 表示值网络第 i 次迭代的参数，每次迭代按照如下(8)式的目标进行，即

$$y = \begin{cases} r + \gamma \max_a \hat{Q}(s_{t+1}, a; \theta_i^-), & \text{如果一轮订货完成} \\ r, & \text{其他} \end{cases} \quad (8)$$

其中 $\gamma \in [0, 1]$ 是折扣因子，即后期收益的折

现， a' 表示 s_{t+1} 状态下所有可能的决策值， θ_i^- 表示目标网络第 i 次迭代的参数， r 表示回报。每次值网络训练时，都会按照如下(9)式的损失函数进行参数 θ 的第 i 次更新，即

$$f_i(\theta_i) = E_{(s_t, a, r, s_{t+1})} \left[\left(y - Q(s_t, a; \theta_i) \right)^2 \right] \quad (9)$$

目标网络不进行训练，每隔 N 步，目标网络的参数 θ_i^- 使用值网络的参数 θ_i 进行更新。

3.2 人机协同

智慧决策机器人以理论最优决策经验为指导，并在决策出现极大偏离时由决策“老师”施加大强度的干扰，从而做出使得供应链整体服务水平最大的决策，同时使得自身各方面水平得到极大的改善。智慧决策机器人与供应链各个节点的协同措施包括传授经验、限制决策及惩罚机制，具体流程如下图 6 所示。




图 6 智慧决策机器人设计流程图

1) 传授经验。分销商在周期 t 接收下游订单，同时做出两种决策，一种是理性决策如(4)式，一种是智慧决策机器人所做的智慧决策。决策“老师”将理论最优决策教授给智慧决策机器人，智慧决策机器人将这个经验融入自身的学习环境，做出回报最大的决策。

2) 限制决策。智慧决策机器人一边学习人类理论最优决策，一边观察自身所处的决策环境，以 $1-\varepsilon$ 的概率选择 Q 值最大的行动作为决策值，以 ε 的概率随机探索 (11, 40) 范围内的值作为决策值。

$$a_t = \begin{cases} \arg \max_a Q(s_t, a; \theta), & 1-\varepsilon \\ \text{random } a \in (11, 40), & \varepsilon \end{cases} \quad (10)$$

其中， ε 表示探索概率。如果做出决策 a_t 后，分销商的货物能够满足顾客需求，则回报 r_t 增加，其中

$$r_t = \frac{\text{完全满足顾客需求次数}}{\text{订货次数}} \quad (11)$$

3) 惩罚机制。训练前期，在智慧决策机器人根据当前环境进行决策值随机探索

时，会出现决策严重超出理论最优的情形，即，即使有决策“老师”的实时指导，智慧决策机器人也无法学到最优决策。在下游订货不多的情况下，智慧决策机器人过多的向上游订货会出现极大的库存积压，因此，当决

策“老师”观察到智慧决策机器人的积压库存达到相同需求下经典多级供应链对应节点的平均库存时，决策“老师”就会给智慧决策机器人施加严厉的惩罚，禁止其向上游订货。

3.3 核心算法

表 2 核心算法

核心算法：牛鞭效应智慧决策机器人设计

```

1  初始化牛鞭效应环境与智慧决策机器人基础设置
2  For  $t=1:T$  do
3      随机生成顾客需求  $D_t$ ,  $D_t \sim N(\mu, \sigma^2)$ 
4      For  $k=1:4$  do
5          经典多级供应链理性决策者制定决策  $q_t^k$  ——人类专家理论最优决策
6          # 人机协同机制 1: 传授经验
7          智慧决策机器人观察  $s_t = (S_{t-1}^{k=3}, WIP_{t-1}^{k=3}, q_{t-1}^{k=2}, Trans_{t-2}^{k=3}, q_{t-1}^{k=3})$ 
8          # 人机协同机制 2: 限制决策
9          智慧决策机器人以  $\varepsilon$  的概率在理论最优决策经验范围内随机做决策  $a_t$ , 否则就以  $1-\varepsilon$  的概率做决策  $a_t = \arg \max_a Q(s_t, a; \theta)$ 
10         # 人机协同机制 3: 惩罚机制
11         智慧供应链上智慧决策机器人的库存大于经典多级供应链对应节点平均库存，决策“老师”禁止智慧决策机器人向上游订货，即  $a_t = 0$ 
12         智慧决策机器人获得当期收益  $r_t$ 
13         智慧决策机器人观察  $s_{t+1} = (S_t^{k=3}, WIP_t^{k=3}, q_t^{k=2}, Trans_{t-1}^{k=3}, q_t^{k=3})$ 
14         将智慧决策机器人的所有信息  $(s_t, a_t, r_t, s_{t+1})$  存储至经验池  $E$ 
15         从经验池  $E$  随机抽取小批量经验  $(s_j, a_j, r_j, s_{j+1})$ 
16         计算  $y_i = r_j + \gamma \max_a Q(s_{j+1}, a; \theta^-)$ , 对  $(y_i - Q(s_j, a_j; \theta))^2$  随机梯度下降来更新值网络的权重  $\theta$ 
17     End for
18     每隔  $N$  步，更新目标网络的权重  $\theta^- = \theta$ 
19 End for

```

4 智慧实验

4.1 实验基础设置

智慧实验将智慧决策机器人接入供应链改善分销商决策，供应链中的其他节点依次按照理性决策^[6]向上游下订单，从方差比、平均成本和服务水平这三个方面进行比较，分析有智慧决策机器人参与下的牛鞭效应新现象。

为便于比较，智慧实验对顾客需求相关参数的假定与复盘时相同，即

$$\rho = 0.5, C_{L,\rho} = 2, d = 10, \varepsilon \sim N(0,5), z = 2, L = 2, p = 5 \quad (12)$$

注：每次实验进行 20000 个周期。

4.2 实验结果与分析




图7 IDMR 训练曲线

图7表示在智慧多级供应链的动态订发货场景下,智慧决策机器人的一系列状态的平均预测行动值,图7上的每一个点都表示在一组状态上计算出的动作Q值的平均

值。如上图7所示,在训练后期,智慧决策机器人的训练曲线逐渐在小范围内上下波动,表明IDMR已经能够做出稳定的使得回报最大的决策。




图8 两种环境下的决策行为对比

IDMR 在理性决策^[6]指导下,经过反复训练,决策行为呈现如上图8所示的特征。如图(c)所示,在面临下游需求信息不稳定的情况下,理性决策者所体现出来的决策行为呈现出相对不稳定的特征,且波动范围较大,但是IDMR的决策行为只是在一定决策范围内来回波动,较稳定。从图(b)来看,智慧决策下分销商的行为集中分布在30左右,偶尔会出现决策为0的情况,并且在分销商稳定的行为影响下,上游制造商的行为也很稳定。但是在理性决策下,如图(a)所示,分销商的决策行为波动很大,会出现一段时间订货,一段时间不订货的情况,导致上游制造商的生产决策行为相对不稳定。

4.2.1 方差比比较

在理性决策下,供应链上各个节点的订货量的方差与需求量的方差之比会出现图2中的情况,随着供应链层级的增加,这种由需求信息不对称带来的方差比越来越大,具体数据如表3理性决策一栏所示。反观,当智慧决策机器人接入供应链用以改善分销商的决策时,如表3中智慧决策一栏所示,

在需求均值与订单均值近似一致的情况下,这种由需求信息不对称带来的订货量的方差与需求量的方差之比有所减小,特别是分销商与制造商,但是批发商的方差比也有一定程度的减小,详见图9。同时如图9所示,随着顾客需求信息的逐级传递,供应链节点根据不对称的需求信息做出补货决策,智慧决策机器人通过观察当前状态做出最优决策,导致整个供应链的订货量与需求量的方差比大小顺序发生了一定程度的变化,最大的节点由原来的制造商变成了批发商,但是从零售商到分销商再到制造商,理性决策下的大小顺序依旧存在。




图9 智慧决策下的方差比

表 3 两种决策下牛鞭效应对比(保留小数点后 2 位)

决策节点	理性决策			智慧决策		
	需求(均值)	订单(均值)	方差比	需求(均值)	订单(均值)	方差比
零售商	19.48	19.48	5.42	19.48	19.48	5.46
批发商	19.48	19.49	27.19	19.48	19.49	22.91
分销商	19.49	19.53	110.33	19.49	19.51	8.70
制造商	19.53	19.66	359.44	19.51	19.51	14.53

4.2.2 平均成本比较




图 10 智慧决策下的平均成本

在成本由库存成本和缺货成本这两者构成时,如图 3 所示,在理性决策下,随着供应链层级的增加,零售商到制造商的平均成本逐级增加,并且相邻两级之间平均成本的差距越来越大。但是在智慧决策下,如上图 10 所示,当智慧决策机器人接入供应链后,供应链的整体成本得到明显减小,其中批发商的成本得到细微减小,而从分销商和制造商的成本可以看出,智慧决策可以有效减小供应链上游成本,其中,对制造商成本的减小作用尤为显著。

4.2.3 服务水平比较




图 11 智慧决策下供应链各级服务水平

图 11 表示当 $z=2$ 时,智慧决策机器人代替分销商做决策时,各级的实际服务水平。如图 4 所示,在理性决策下,即使理论目标服务水平是 97.7%,实际上由于运输提前期

的存在,供应链上除了制造商之外,各级都不能达到 97.7%的服务水平。相反,如上图 11 所示,当智慧决策机器人接入供应链用以改善分销商决策时,上游节点的服务水平都有所提高,尤其是分销商,相比于传统决策下的服务水平,分销商的 SL 提高了接近 4.2%,实际服务水平接近 100%。

5 结束语

本文研究并设计了智慧决策机器人,将智慧决策机器人接入四级供应链改善分销商决策,通过比较理性决策与智慧决策在方差比、平均成本以及服务水平等三个方面的差异,发现了缓解牛鞭效应的新途径。主要结论如下:

1) 牛鞭效应得到极大缓解。在理性决策下,经典多级供应链模型下的牛鞭效应顺序依次是零售商、批发商、分销商和制造商,但是智慧决策机器人所参与的智慧多级供应链模型下的牛鞭效应顺序依次是零售商、分销商、制造商和批发商,但是从数值上看,相对于理性决策,批发商在智慧决策下的方差比更小。

2) 牛鞭效应所对应的各项指标全面改进。在理性决策下,按照经典供应链模型顺序,从零售商到制造商,各节点成本和服务水平都呈逐级上升的态势。但是在智慧决策下,制造商成本最低,分销商的服务水平最高,其他各节点成本和服务水平保持原有顺序不变。

3) 供应链各个节点的相互关系发生较大改变。在经典多级供应链模型下,各个节点相互依存相互协调,任何节点决策制定都离不开当前已知的所有条件,要达到缓解牛鞭效应的目的,最重要的手段就是信息共享。但是在智慧决策供应链模型下,智慧决策机器人可以在不接收顾客需求信息情况下达到缓解牛鞭效应的目的,各节点之间的相互依赖关系得到极大的减弱。

尽管本文设计的智慧决策机器人有效

缓解了简单四级供应链下的牛鞭效应，特别是改善了分销商和制造商的库存，但是本研究还存在如下几点问题。首先，市场环境下的供应链十分复杂，在这种复杂的环境下，智慧决策机器人是否依然能在决策“老师”的指导下表现出稳定的行为特征。其次，当一条供应链中存在多个智慧决策机器人时，节点之间是否能够有效协调，并做出提高整个供应链收益的决策。因此，智慧决策机器人是否能够适应复杂的环境以及协调好多个机器人参与下的供应链，这都是有待深究的问题。

参考文献

- [1] Lee H L, Padmanabhan V, Whang S, et al. Information distortion in a supply chain: the bullwhip effect[J]. *Management Science*, 1997, 43(4): 546-558.
- [2] Lee H L, Padmanabhan V, Whang S, et al. The Bullwhip Effect in Supply Chains[J]. *Sloan Management Review*, 1997, 38(3): 93-102.
- [3] Forrester J W. *Industrial Dynamics*[M]. Cambridge Mass: MIT Press, 1961.
- [4] Sterman J D. Modeling managerial behavior: Misperceptions of feedback in a dynamic decision making experiment[J]. *Management Science*, 1989, 35(3): 321-339.
- [5] Cachon G P, Fisher M. Supply chain inventory management and the value of shared information[J]. *Management Science*, 2000, 46(8): 1032-1048.
- [6] Chen F, Drezner Z, Ryan J K, et al. Quantifying the bullwhip effect in a simple supply chain: The impact of forecasting, lead times, and information[J]. *Management Science*, 2000, 46(3): 436-443.
- [7] Dejonckheere J, Disney S M, Lambrecht M, et al. The impact of information enrichment on the Bullwhip effect in supply chains: A control engineering perspective[J]. *European Journal of Operational Research*, 2004, 153(3): 727-750.
- [8] Odonnell T, Maguire L, Mcivor R, et al. Minimizing the bullwhip effect in a supply chain using genetic algorithms[J]. *International Journal of Production Research*, 2006, 44(8): 1523-1543.
- [9] Badakhshan E, Humphreys P, Maguire L, et al. Using simulation-based system dynamics and genetic algorithms to reduce the cash flow bullwhip in the supply chain[J]. *International Journal of Production Research*, 2020: 1-27.
- [10] Tsay A A, Lovejoy W S. Quantity flexibility contracts and supply chain performance[J]. *Manufacturing & Service Operations Management*, 1999, 1(2): 89-111.
- [11] Eppen G D, Iyer A V. Backup agreements in fashion buying—the value of upstream flexibility[J]. *Management Science*, 1997, 43(11): 1469-1484.
- [12] Disney S M, Towill D R. The effect of vendor managed inventory (VMI) dynamics on the Bullwhip Effect in supply chains[J]. *International Journal of Production Economics*, 2003, 85(2): 199-215.
- [13] 陈佳莉, 郭春香. 基于卡尔曼滤波需求预测的牛鞭效应研究 [J]. *管理学报*, 2019, 16(05): 775-782.
Chen Jiali, Guo Chunxiang. Research on Bullwhip Effect Based on Demand Forecast with Kalman Filter[J]. *Chinese Journal of Management*, 2019, 16(05): 775-782.
- [14] 尤建新, 隋明刚, 霍佳震. 闭环供应链牛鞭效应分析 [J]. *系统工程理论与实践*, 2007(12): 111-116.
You Jianxin, Sui Minggang, Huo Jiazhen. Bullwhip Effect in Closed-Loop Supply Chain[J]. *Systems Engineering-Theory & Practice*, 2007(12): 111-116.
- [15] 唐亮, 靖可. H^∞ 鲁棒控制下动态供应链系统牛鞭效应优化 [J]. *系统工程理论与实践*, 2012, 32(1): 155-155.
Tang Liang, Jing Ke. Bullwhip effect optimization of dynamic supply chain system based on H^∞ robust control[J]. *Systems Engineering — Theory & Practice*, 2012, 32(1): 155-155.
- [16] 陈长彬, 盛鑫, 梁永奕. 一种减少供应链牛鞭效应的资产组合管理方法 [J]. *管理科学学报*, 2016, 19(06): 33-48.
Chen Changbin, Sheng Xin, Liang Yongyi. Reducing bullwhip effect in supply chain: A portfolio management approach[J]. *Journal of Management Sciences in China*, 2016, 19(06): 33-48.
- [17] Carbonneau R, Laframboise K, Vahidov R. Application of machine learning techniques for supply chain demand forecasting[J]. *European Journal of Operational Research*, 2008, 184(3): 1140-1154.
- [18] Hinton G E, Salakhutdinov R R. Reducing the dimensionality of data with neural networks[J]. *science*, 2006, 313(5786): 504-507.
- [19] Kong F, Li J. The promotion strategy of supply chain flexibility based on deep belief network[J]. *Applied Intelligence*, 2018, 48(5): 1394-1405.
- [20] 张荣, 李伟平, 莫同. 深度学习研究综述 [J]. *信息与控制*, 2018, 47(04): 385-397+410.
Zhang Rong, Li Weiping, Mo Tong. Review of Deep Learning[J]. *Information and Control*, 2018, 47(04): 385-397+410.
- [21] Mnih V, Kavukcuoglu K, Silver D, et al. Playing atari with deep reinforcement learning[J]. *arXiv preprint arXiv: 1312.5602*, 2013.
- [22] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. *Nature*, 2015, 518(7540): 529-533.
- [23] Oroojlooyjadid A, Nazari M R, Snyder L, et al. A Deep Q-Network for the Beer Game: A Deep Reinforcement Learning algorithm to Solve Inventory Optimization Problems[J]. *arXiv preprint arXiv: 1708.05924*, 2017.
- [24] Chien C F, Lin Y S, Lin S K. Deep reinforcement learning for selecting demand forecast models to empower Industry 3.5 and an empirical study for a semiconductor component distributor[J]. *International Journal of Production Research*, 2020, 58(9): 2784-2804.

A new way to alleviate bullwhip effect: An intelligent decision-making robot based on man-robot cooperation

LI Yong, CHEN Yuan, YU Hui

(School of Economics and Business Administration, Chongqing University, Chongqing 400030, China)

Abstract: Bullwhip effect refers to the phenomenon of demand variation and gradual amplification in the supply chain, which will bring high costs to supply chain enterprises. Therefore, alleviating the bullwhip effect has always been one of the core tasks of supply chain management, but the existing methods still cannot completely eliminate bullwhip effect. Introducing artificial intelligence methods into the supply chain to create a smart supply chain is one of the main methods for supply chain management in the information age, and it is also the main source of ideas to study the bullwhip effect. To explore new ways to alleviate the bullwhip effect, this paper constructs a four-level supply chain consisting of a retailer, a wholesaler, a distributor and a manufacturer, introduces the deep reinforcement learning technology in artificial intelligence into supply chain management, and designs a human-machine collaborative intelligent decision-making robot, used to improve the decision-making of distributors in the supply chain. The results of the smart experiment show that the indicators such as "variance ratio, average cost and service level" of each node in the supply chain have been comprehensively improved, which means that the bullwhip effect has been greatly alleviated. This paper provides a new perspective and approach for studying the bullwhip effect in supply chain management, and endows supply chain management with the value of intelligent decision-making.

Keywords: bullwhip effect; human-machine collaborative; intelligent decision-making robot; supply chain management

附录

实验参数设置

IDMR 的各参数设置如表 1 所示。

表 1 IDMR 基本参数设置

超参数	值	释义
minibatch size	32	计算每个随机梯度下降 (SGD) 更新的训练案例数
replay memory size	20000	SGD 更新是从最近的 20000 个样本中取样
replay start size	100	当样本池大小大于 100 时, IDMR 开始训练, 训练结果用来填充记忆回放
initial exploration	1	在 ε -greedy 探索中 ε 的初始值
final exploration	0.01	在 ε -greedy 探索中 ε 的最终值
learning rate	1e - 4	Adam 优化器使用的学习率
discount factor	0.9	在 Q-learning 中使用的折扣系数 γ
target network upd-ate start size	400	当样本池大小大于 400 时, 开始有间隔的更新目标网络参数
target network update frequency	10	每隔 10 步将值网络的参数 θ 更新到目标网络的参数 θ^-
iteration	20000	一个回合进行 20000 个周期(week)
state space	5	供值网络训练的 IDMR 的一个经验的长度
action space	40	IDMR 探索时的决策探索范围
activation function	relu	将数据进行非线性处理, 提高数据训练模型的拟合度

理性决策下的需求与订单




图1 理性决策下各节点的需求与订单

如上图1所示,在理性决策下,当顾客需求以稳定的随机信号输入且为线性时,经

过20000个周期的连续订货与发货,各个节点的需求均值与订单均值近似相等。

智慧决策下的需求与订单




图2 智慧决策下各节点的需求与订单

如上图2所示,在智慧决策下,当智慧多级供应链上的顾客需求假定与经典多级供应链下的相同时,各个节点的需求均值与订单均值近似相等。

成本构成

供应链各节点总成本构成及各决策方式下成本对比如图3和图4所示,包含库存成本和缺货成本。




图3 库存成本

如图(a)所示,在经典多级供应链上,随着顾客需求的逐级传递,各级库存逐级增加,

在制造商处达到最大，其库存量是零售商的42倍。但是，当智慧决策机器人接入经典供应链改善分销商决策时，如图(b)所示，库存

量的传递出现了变化，制造商的库存量比分销商小，居供应链库存排名第三位。




图 4 缺货成本

如图(a)所示，在经典多级供应链上，随着顾客需求的逐级传递，各级缺货逐级增加，在制造商处达到最大。但是，当智慧决策机器人接入传统供应链改善分销商决策时，如

图(b)所示，缺货量的传递出现了变化，制造商的缺货量达到最小，20000个周期的平均缺货量约为0.22，分销商的缺货量达到最大。

在途库存




图 5 在途库存

各节点在途库存如图 5 所示，在经典多级供应链下和智慧多级供应链下，各级的在

途库存趋于相同，在一定程度上都可以保证下游的供应。

同一维度方差

维度指的是每 500 个周期计算一次方差。




图6 同一维度方差

各节点同一维度方差如图6所示,在经典多级供应链下,如图(a)所示,决策方差呈现逐级递增的现象,但是在智慧多级供应链下,如图(b)所示,这种现象不再存在,决策

方差的大小顺序依次是零售商、分销商、制造商和批发商。而且,在智慧多级供应链下,除零售商,其他节点的方差都比经典多级供应链小。